


Relatório 3 - Tarefas de Visão com Deep Learning I (II)


Lucas Scheffer Hundsdorfer

Descrição da atividade


A aula começa com a professora se apresentando e apresentando quem vai participar da aula com ela e depois começa a falar de qual vai ser o escopo da aula:




O conteúdo vai ser bem a junção entre a visão computacional com o deep learning. A aula conta um pouco do passado da visão, como os primeiros seres no mundo que conseguiam captar luz, datados em 540 milhões de anos antes de Cristo e também de uma câmera escura de Leonardo Da Vinci que é uma caixa escura com um furo pequeno para passar a luz no qual do outro lado reflete a imagem invertidamente:



É destacado que um dos maiores problemas da visão computacional seria capturar algo do nosso mundo que é em 3 dimensões e passar para algo que é em 2 dimensões. E vai sendo passado de época em época de como a visão computacional foi avançando, citando grandes contribuições de várias pessoas, como na década de 70 quando conseguiram fazer o reconhecimento de objetos e na década de 80 a detecção de bordas. É feito vários estudos de como o cérebro humano reconhece cenários e de como categoriza cada um deles, esses estudos são importantes para demonstrar como o cérebro é bom nisso e para ver como é feito toda essa análise para conseguir ter um entendimento melhor para toda a visão computacional. E um dos pontos em que fez a visão computacional avançar foi que no começo do século 21 com a chegada da internet e das fotografias digitais, começou um acúmulo de dados que beneficiaria a visão computacional de forma indireta pelo fato do deep learning se beneficiar com grandes quantidades de dados. Os algoritmos de redes neurais e as arquiteturas deles já existiam por volta da década de 80, porém a falta de dados era o que fazia com que eles não se tornassem tão eficientes e se tornarem algo fora do 'mainstream' das pesquisas. É explicado que em 2012 aconteceu o que pode ser chamado de 'nascimento' do deep learning que foi quando através de uma competição do ImageNet para ver quem conseguiria ter melhor desempenho de reconhecimento de imagens dentro do dataset. Com essa competição surgiu o AlexNet que foi uma rede neural que conseguiu utilizar do backpropagation para aumentar a capacidade do algoritmo trazendo outros olhos para a área. Como esses gráficos podem demonstrar:



Após isso é explicado o básico de algumas tarefas dentro da visão computacional:



A classificação de imagem é o mais simples, apenas retorna uma classe para a imagem. A segmentação semântica é quando se retorna uma label para cada pixel da imagem. Detecção de objetos é detectar e desenhar quadrados em cada objeto pertencente a imagem e por fim Segmentação de Instância é a combinação da segmentação e da detecção, rotular cada pixel do objeto.

O segundo vídeo também da Universidade de Stanford começa explicando que existem desafios dentro da classificação de imagem já que o computador enxerga apenas os pixels. Existe um problema dentro da variação de ponto de vista, se tirar uma foto de um gato de dois pontos de vista diferentes todos os pixels da imagem vão mudar. Outro problema é a iluminação da imagem que pode variar e deixar mais fácil ou mais complicado para a classificação. E outro tipo de desafio é que os objetos da mesma classe podem apresentar formatos diferentes. Para fazer a classificação de imagem o método mais escalável tanto para acurácia do modelo como para reconhecimento de inúmeros objetos é a abordagem baseada em dados, onde é coletado um dataset junto das classes, é usado machine learning para treinar e classificar e após o treinamento utilizar novas imagens para avaliar o resultado do treino. É falado sobre o classificador K-Nearest Neighbors, e é um classificador que a partir do treino do machine learning, salva todas as imagens em memória e após isso, para fazer a classificação de uma nova imagem, ele calcula a distância baseada nas diferenças entre as fotos e classifica com a que é mais parecida de acordo com as imagens vistas dentro do treino. E é mostrado duas formas que podemos calcular as distâncias de imagens:

K-Nearest Neighbors: Distance Metric

L1 (Manhattan) distance


$$d_1(I_1, I_2) = \sum_p |I_1^p - I_2^p|$$



K = 1

L2 (Euclidean) distance

$$d_2(I_1, I_2) = \sqrt{\sum_p (I_1^p - I_2^p)^2}$$



K = 1

O que L1 e L2 fazem é fazer a soma da diferença dos pixels das imagens, com L1 sendo a diferença absoluta e L2 raiz quadrada da diferença ao quadrado. Após a explicação do classificador é explicado o que é um hiperparâmetro, os hiperparâmetros são as escolhas sobre o algoritmo em si que não se pode ser aprendido com os dados e é explicado qual a melhor maneira de validar e escolher os valores para esses hiperparâmetros:

Setting Hyperparameters


Idea #1: Choose hyperparameters that work best on the data

BAD: $K = 1$ always works perfectly on training data



Idea #2: Split data into **train** and **test**, choose hyperparameters that work best on test data

BAD: No idea how algorithm will perform on new data




Idea #3: Split data into **train**, **val**, and **test**; choose hyperparameters on val and evaluate on test

Better!




Separando em 3 maneiras de pensar e do porquê não fazer algumas delas. O primeiro método seria utilizar todo o dataset para treino, e isso não é a maneira adequada pois provavelmente vai funcionar apenas no seu dataset, o que é chamado de overfitting. A segunda maneira de pensar é separar em dados de treino e teste e escolher os melhores valores baseados em qual funcionou melhor nos dados de teste, o que também é uma má ideia pelo mesmo motivo, não saber como vai funcionar em dados novos. E a terceira maneira que é a mais recomendada é separar o dataset em dados de treino, validação e teste, o que vai fazer com que os dados sejam validados no dataset de validação e vai ser onde os hiperparâmetros vão ser avaliados, se estão funcionando ou não e o dataset de teste serve para avaliar o resultado do modelo baseado em dados nunca vistos.


Existem outros métodos para ajustar os hiperparâmetros, como o cross validation que sugere separar o seu dataset entre algumas partes e ir separando os dados de treino e de validação:



Como na imagem acima é mostrado, é separado 4 partes de treino e 1 para validação, e eles vão sendo trocados a cada split, isso implica que o modelo se torne mais confiável porque está variando o conjunto de validação, o que ajuda a reduzir o overfitting. Normalmente mais utilizado em menores conjuntos de dados o que acarreta a pouca utilização dentro do deep learning pelo fato de que isso levaria a muitos mais treinos e demandaria muito custo computacional. É falado de outro tipo de classificador já que o K-Nearest Neighbors não é o mais adequado para imagens. O classificador linear que diferentemente do outro classificador não armazena todas as imagens em memória e sim salva apenas em uma matriz de pesos, faz a classificação baseada em um vetor dos pixels da imagem multiplicado por essa matriz de peso e somado ao um viés ou bias:



INSIGHT VISUAL ORIGINAL:



Dificuldades

Não encontrei nenhuma dificuldade nesse card, pelo fato de ser apenas teórico.

Conclusões

Posso concluir que os estudos dentro da área da visão computacional vem de bem antes do que eu esperava, já existiam estudos dentro da área porém só foi começado a dar valor a essa área no começo do século XXI com a chegada da internet e com o acúmulo de dados digitais e vendo que era possível se juntar a área de Deep Learning e utilizando dos algoritmos de redes neurais fazendo com que a visão computacional avançasse bastante nesse período.

Atualmente é um campo bem complexo que envolve várias tarefas, cada uma com seu objetivo diferente. Superar desafios como variações de iluminação e ponto de vista tornou-se possível através de abordagens baseadas em dados, onde modelos de Classificação Linear e técnicas rigorosas de validação, como o Cross-validation, evitando o *overfitting* e consolidando a visão computacional como um pilar fundamental da inteligência artificial moderna

Referências

- ▶ Stanford CS231N Deep Learning for Computer Vision | Spring 2025 | Lecture 1: Introducti...
- ▶ Lecture 2 | Image Classification