


Relatório 4 - Tarefas de visão com Deep Learning II


Lucas Scheffer Hundsdorfer

Descrição da atividade


O começo da aula é a explicação de algumas das outras tarefas de visão computacional que não são classificação de imagem. Segmentação semântica é uma das tarefas que envolve classificar todos os pixels da imagem e não apenas rotular a imagem como algo, cada pixel da imagem vai receber uma categoria:




A segmentação semântica só vai se importar com os pixels e não com as instâncias, se tiver dois gatos juntos não vai ser feita a diferenciação dos gatos apenas identificar que são gatos. É explicado alguns modos de que essa tarefa poderia ser feita, como aplicar a classificação de imagem para cada pixel, porém isso exigiria muito poder computacional e não é aplicado, outra possível forma possível é com uma rede totalmente convolucional, aplicando sucessivas camadas de convolução com padding para preservar a imagem, mas o que também utilizaria de muito poder computacional. O jeito mais adequado de fazer a segmentação semântica é com uma rede neural totalmente convolucional com redução de resolução e depois aumento, dessa forma:



E existem várias maneiras de fazer esse aumento de resolução, utilizando como por exemplo o unpooling, tanto o nearest neighbor como o “bed of nails”:




O Nearest Neighbor consiste em apenas multiplicar o valor existente para encaixar na nova resolução e o "bed of nails" em colocar apenas um valor e o restante deixar zerado. É uma forma mais adequada ainda seria o Max Unpooling, que consiste em salvar as posições do Pooling original para quando ser feito o Unpooling ele aplicar para os mesmos lugares:



Outra tarefa da área de visão computacional é a classificação junto da localização:

Classification With Localization:

Convert any Keras Classifier to a Detector




learnopencv.com

Agora invés de classificar uma imagem ou todos os pixels, o que vai ser feito vai ser localizar o que é desejado e desenhar um "bounding box" sobre ele com a categoria na qual ele pertence.

A rede neural da tarefa de classificação e localização é um pouco diferente da anterior vista, ela vai manter as camadas de convolução mas ao chegar ao final ela vai resultar em 2 saídas, uma para a categoria do objeto classificado e outra para as coordenadas do "bounding box". Como são duas tarefas, vão existir duas funções de perda, para o tarefa de classificação vai ser normalmente utilizada uma função softmax já que vai retornar uma probabilidade da rede ter acertado o rótulo, já a localização vai utilizar uma função de erro quadrático médio.

A outra tarefa a ser citada é a detecção de objetos, nas quais vão ter uma quantidade de objetos que vai ser detectado e toda vez que esses objetos específicos aparecem

na imagem é para ser nomeado e desenhado:



A diferenciação da classificação e localização é que aqui nesse caso não se sabe quantos objetos irão aparecer na imagem. A classificação e localização sempre vai ser apenas um.

A detecção de objetos como outras tasks dentro da visão computacional se beneficiaram muito após o “descobrimento” do deep learning, como mostra o gráfico abaixo:

Object Detection: Impact of Deep Learning





Figure copyright Ross Girshick, 2015.
Reproduced with permission.

Os capítulos passados do livro do Szeliski, começam dizendo sobre os métodos e algoritmos utilizados anteriormente para detecção de faces, é citado Clustering and PCA, Redes Neurais, Support Vector Machines (SVMs), Boosting e também Redes Profundas. Todos esses algoritmos compartilhavam uma característica fundamental, a dependência de classificadores treinados em conjuntos de patches rotulados de faces e não-faces. É passado por cima de algumas métricas da detecção de objetos como o IoU ou Intersection over Union e também sobre a precisão e o recall. É falado também sobre os novos detectores de objetos baseados em redes neurais que são as R-CNN as Region-based CNN, que começa extraindo cerca de 2000 regiões usando um algoritmo de busca selecionado, cada uma dessas regiões vai ser redimensionada para 224x224 e passada para uma rede neural como alexNet ou VGG com um suporte de uma SVM como classificador final.

Também é passado por cima pelas explicações do que são as outras tasks da visão computacional, como a segmentação semântica, segmentação de instância e segmentação panóptica e a aplicação de cada de casos reais. A segmentação de imagens é muito utilizada dentro do domínio médico, onde pode ser usada para segmentar problemas anatômicos:



A segmentação de instância é utilizada para achar cada pixel dos objetos mais relevantes da imagem, muito utilizada para produzir máscaras precisas para as regiões visíveis de cada objeto individualmente:




E por fim a segmentação panóptica que é a junção das 2 outras tasks, a segmentação de instância que foca em detectar individualmente cada objeto, junto da segmentação semântica que detecta cada pixel da imagem em categorias. Sendo assim a segmentação panóptica atribui a cada pixel da imagem tanto um rótulo de classe

quanto um identificador de instância, resultando em uma representação onde todos os objetos são corretamente segmentados e o restante do cenário é devidamente rotulado:



INSIGHT VISUAL ORIGINAL:



Dificuldades

Não encontrei nenhuma dificuldade.

Conclusões

A conclusão que eu chego com o vídeo e a leitura concluída é que a visão computacional vai muito além da classificação de imagens que é o campo mais conhecido da área. Essas outras tarefas como detecção de objetos e todas as segmentações trazem muito mais importância para a área pelo fato de poderem ser muito aplicadas dentro de toda a indústria, como na medicina, onde a segmentação de imagens volumétricas 3D é utilizada para identificar com precisão de pixel tecidos

anatômicos e tumores cerebrais, substituindo o antigo e trabalhoso processo de traçado manual em fatias de raios-X.

Referências

 [Lecture 11 | Detection and Segmentation](#)