

# Relatório 1 - Prática: Fundamentos de NLP

Lucas Scheffer Hundsdorfer

## Descrição da atividade

- Introdução ao NLP

O vídeo é bem simples mas já dá uma base introdutória ao NLP e onde é explicado o que é e onde é utilizado no dia a dia da maioria, como correção ortográfica automática e também verificação de plágio em textos. É explicado o passo a passo também de como é feito o NLP, primeiramente a segmentação que separa em frases menores o texto todo, depois disso é feita a tokenização, que é separar cada palavra dessa frase e dar um valor a ela, depois é feito um processo chamado de *stemming* que ensina a máquina que cada palavra e seu derivado tem os mesmos significados (pular, pulando, pulou), e tem também o *lemmatization* que busca fazer algo parecido com o *stemming* mas transforma a palavra em seu lema (pular -> pulo). Após isso é feito outro processo para a máquina identificar o que cada palavra é dentro da gramática, verbos, substantivos ou adjetivos.

- Formação Processamento de Linguagem Natural e LLM
  - 1. Introdução

O vídeo de introdução já começa trazendo alguns fatos de que a área de NLP tem muita a expandir, muita demanda no mercado, mas também se trata de uma área com uma complexidade maior, dado ao fato que as linguagens são ambíguas, palavras tem mais de um significado e dependendo da posição da palavra na frase pode mudar o significado. Outro problema também é a ironia, para identificar e detectar ironia em uma frase pode ser muito complicado, porém se tem conseguido êxito nessa área, o autor do vídeo deu créditos direto a inteligência artificial.

O segundo vídeo é mais para uma explicação de aplicações do NLP dentro do cotidiano, como tradução de texto, análise de sentimentos, sintetização de fala, previsão de digitação, classificação de textos e documentos, chatbots, reconhecimento de autoria de documentos, análise sintática, busca de similaridade, reconhecimento de entidades nomeadas, produção de resumos de texto. Já dá para ter uma noção do tamanho que o NLP representa e o quão presente ele é no dia a dia da maioria dos seres humanos.

- 2. Fundamentos de Processamento de Linguagem Natural


Aqui nesta seção vai ser mostrado alguns conceitos/fundamentos específicos do NLP, começando com Corpus, que é o conjunto de documentos em texto não estruturado em linguagem natural, podendo se dizer que são os textos brutos, antes do pré processamento. Temos também as anotações, que basicamente rotulam os dados dentro de uma base de dados, para futuramente ensinar o modelo. *Tokenization* é outro contexto utilizado, para o que já foi apresentado, separar as palavras de uma sentença. *Parts-of-Speech* é outro conceito, também já dito no primeiro vídeo, mas é o que adiciona tags para cada token (verbo, substantivo, adjetivo). Outro é o *Lemmatizing* que também já tinha sido visto, mas agora de uma forma mais didática:

## Lemmatizing (Lemma)

Traz a palavra na sua flexão, de modo que possam ser analisadas juntas

| Nossa vida é controlada por algoritmos, |        |      |            |                       |            |      |
|-----------------------------------------|--------|------|------------|-----------------------|------------|------|
| Nossa                                   | vida   | é    | controlada | por                   | algoritmos | ,    |
| Pron /Interj                            | Subst. | Verb | Adj        | Prep/<br>LOC.<br>ADVL | Subst.     | Pont |
| meu                                     | vida   | ser  | controlado | por                   | algoritmo  | ,    |

O *Stemming* é apresentado como a solução do mesmo problema porém de forma mais rudimentar, porque da forma como ele é feito, ele corta palavras, buscando ter uma representação única para elas. Outro conceito mostrado é o *Dependency Parsing* que encontra relação de “pais e filhos” na sentença. Como na imagem abaixo, utilizando a sentença Nossa vida é controlada por algoritmos,:



O NGRAM é o conceito de quando o processamento da linguagem natural vai tratar palavras consecutivas, indo até 3 palavras, a partir disso não é usado devido à esparsidade. Tem também o modelo que se trata de um banco de dados linguístico, específico para cada idioma.

É dado uma breve explicação de que os computadores não entendem informação da mesma forma que nós humanos, então é preciso criar uma forma de representar esses textos para que o computador consiga entender isso. Nisso é apresentado o *Word Embedding* que é uma representação dos textos para os computadores, podendo ser independente de contexto ou dependente. Algumas formas de fazer isso são apresentadas, a primeira *One Hot Encoding*:

|            | algoritmos | controlada | é | Nossa | por | vida |
|------------|------------|------------|---|-------|-----|------|
| Nossa      | 0          | 0          | 0 | 1     | 0   | 0    |
| vida       | 0          | 0          | 0 | 0     | 0   | 1    |
| é          | 0          | 0          | 1 | 0     | 0   | 0    |
| controlada | 0          | 1          | 0 | 0     | 0   | 0    |
| por        | 0          | 0          | 0 | 0     | 1   | 0    |
| algoritmos | 1          | 0          | 0 | 0     | 0   | 0    |

Que é criado um vetor com a quantidade de palavras na sentença e preenchido de 0 e colocado 1 na palavra onde ele representa, alguns problemas derivados é que se tiver um Corpus muito grande, automaticamente vai se ter uma matriz muito grande. Outra forma é o TF-IDF que representa as palavras de acordo com a frequência dela nos documentos, ele basicamente vai trazer pesos para as palavras. Outra forma também é o Word2Vec que vai produzir um vetor que demonstra a ocorrência da palavra e a relação entre elas.

As seções 3 e 4 do curso (NLP com Spacy e NLP com NLTK) respectivamente são mais práticas, mas o que foi desenvolvido dentro dela foi basicamente a aplicação dos conceitos aprendidos nas seções anteriores. Foi um pouco de como usar o Google Colab como ambiente, e a parte prática para ambas as bibliotecas foi praticamente a mesma, produção de tokens, POS, stopWords, e as entidades presentes dentro do texto. A única divergência foi que o Spacy se mostrou mais robusto em relação ao NLTK, apresentando mais funcionalidades como a de busca de similaridade e por matching, a possibilidade de uma visualização mais interessante com o displacy e também mostrando a possibilidade de alteração na pipeline.

- Machine Learning Models for NLP

Um texto bem curto demonstrando a evolução dos modelos de machine learning e que o NLP foi se acostumando e utilizando a cada melhoria. Começa explicando que o NLP é um subcampo da IA que busca compreender e gerar textos em linguagem natural, detalhando que o avanço do NLP se dá diretamente ao avanço dos modelos de ML, como os modelos baseados em transformers. Também é dada uma breve explicação dos modelos que são sistemas reais treinados em datasets que tentam fazer complexas relações entre a entrada e saída de dados, e que modelos pré-treinados salvam muito tempo e poder computacional. Após a breve introdução é explicado um pouco sobre a evolução dos modelos ao longo do tempo, começando em SVM até os dias de hoje com os transformers e os modelos de linguagem pré treinados.

## **Conclusões**

Com essas atividades concluídas, consigo dizer que o NLP é uma área de estudos muito interessante e já muito utilizada no meu dia a dia sem eu saber. É de grande aprendizado o entendimento mais básico de ambas bibliotecas, tanto o spacy como o NLTK mesmo sendo simples ainda tem várias aplicações muito interessantes para se fazer.

## **Referências**