

Relatório 2 - Introdução a modelos Transformers

Lucas Scheffer Hundsdorfer


Descrição da atividade

- O que são transformers?

O vídeo começa explicando a sigla GPT que significa Generative Pre-Trained Transformer e explicando que ele é o responsável pelo boom da IA atualmente, e citando um pouco das utilidades dele, como text-to-voice que pega textos e sintetiza uma voz, text-to-image que pega um texto e transforma em imagens. E dito que o attention is all you need o artigo que deu origem aos transformers tinha apenas a intenção de traduzir texto. Porém aplicado de outra forma ele virou um preditor das possíveis próximas palavras a partir de um determinado texto, e fazendo um looping de receber texto -> colocar palavra mais provável -> passar texto para o transformer é possível que se tenha algo que faça sentido com um modelo grande. E essa é a base do que acontece quando se está conversando com os modelos de linguagem dos dias de hoje. Explicando a atenção que seria o processo dos embeddings alterarem os seus valores baseados no contexto deles, como o exemplo dado: “a machine learning model” e “a fashion model” baseado no contexto “model” tem uma diferença de significado. E dentro do processo de repetir muitas vezes a camada de atenção e de perception layers no final vai se ter um vetor no qual te dará as probabilidades de uma certa palavra ocorrer depois da sentença. Explicado também de forma breve um pouco sobre deep learning e machine learning e sobre os embeddings, foi muito falado sobre como o espaço vetorial consegue nos dar algumas informações interessantes, como que cada palavra se relaciona com a outra e como podem ser calculados de forma não precisa mas ainda sim muito útil. Também é citado a capacidade do modelo, a janela de contexto, basicamente a quantidade de tokens/embeddings que o modelo consegue suportar, o que aos modelos mais antigos ficava complicado manter uma conversa muito longa sem ele se perder no meio. Outro conceito interessante apresentado é a temperatura, algo que vai afetar a escolha de palavras baseada na probabilidade dada pela função softmax, quanto menor temperatura os valores da probabilidade vão sendo distribuídos de forma menos uniforme, sendo temperatura = 0 a probabilidade de X palavra vai ser 100%, já se a temperatura for maior as probabilidades vão sendo distribuídas de forma mais igual.

- Transformers, Bert, GPT e mais

A primeira aula é focada na explicação de como funciona um transformer. Então é começado a explicação de encoder e decoder, primeiramente o encoder é alterar a informação de uma forma que o computador compreenda e o decoder é voltar para a informação para o formato original. Explicando mais a fundo, o encoder é composto por algumas camadas empilhadas de encoders, mas antes dessas camadas vem o positional encoding, que basicamente vai trazer ordem das palavras dentro dos embeddings. E dentro de encoder vão ter 4 camadas, uma de multi-head attention, add & norm, Feedforward network e outra add & norm. É feita toda uma explicação detalhada dos cálculos presentes do self-attention para explicar como funciona de fato o multi-head attention, que é basicamente a soma de vários processos de self-attention no mesmo embedding que depois são multiplicadas porque a rede neural vai esperar apenas uma matriz. A camada de Add & Norm é apenas uma camada de normalização que busca conectar e normalizar. O decoder funciona de forma muito semelhante, primeiramente tem o positional encoding, depois algumas camadas de decoders, porém no final tem uma camada linear e outra de softmax. Dentro dos decoders também é semelhante ao encoder, porém inicialmente tem uma camada de masked multi-head attention. Cada encoder vai receber 2 entradas, a saída do encoder e a saída do decoder anterior. O masked multi-head attention funciona meio que tentando prever a próxima palavra baseada na anterior.



Essa imagem define bem tudo que foi escrito.

Bert significa Bidirectional Encoder Representations From Transformers, ele possui apenas a parte do encoder, já que o objetivo é gerar uma representação da linguagem. O bert apresenta alguns versionamentos de acordo com o tamanho. Todas essas versões foram treinadas com treinamento não supervisionado.

O resto das aulas foram feitas no Google Colab, que trouxeram uma visão mais prática do conteúdo, como resumo de textos, perguntas e respostas, gerador de texto e preenchedor de lacunas, tudo isso utilizando os transformers que foram aprendidos de forma teórica.

Conclusões

A conclusão com esse card é que transformers foi o conceito que deu o estopim para essa era de IA que estamos vivendo hoje, então dá para ver de forma bem consolidada como eles são importantes, mas também como são complexos. É também muito interessante começar a ter mais entendimento de como a LLM que uso todo dia funciona, a questão de token que aparece em todo lugar hoje em dia para comparação de custos. E começar a entender como posso usar de uma melhor forma tendo em mente que é basicamente uma busca pela próxima palavra mais provável.

Referências