

Relatório 3 - Explicabilidade de Modelos

Lucas Scheffer Hundsdorfer


Descrição da atividade

- O que são Word Embeddings? | Processamento de Linguagem Natural | Leonardo Ribeiro

É começado mostrando como que os embeddings podem ter várias formas de serem construídos, o primeiro é o one hot vector:

Labels		Sunny	Rain	Wind
Sunny		1	0	0
Rain		0	1	0
Wind		0	0	1

Funciona dessa maneira, pega a quantidade de palavras que foram codificadas, e transforma no tamanho do vetor, e a de acordo com o índice da palavra é colocado um 1. Porém essa forma tem um problema, a palavra virou um embedding mas ela não tem um significado semântico. Uma das formas de resolver isso foi dar valores baseados nas palavras de contexto, então toda vez as palavras que aparecem próximas ou tem um contexto parecido vão se aproximar dentro do espaço vetorial.



Da mesma forma palavras com a mesma relação tem a mesma distância. Nos casos acima, o masculino e o feminino dos seres humanos para o rei e a rainha e os verbos no inglês no presente e no passado. Dá mesma forma dá para ter uma noção de similaridade de significados das palavras baseado na proximidade deles dentro do espaço.

- Model Explainability

Com a documentação do framework txtai fui descobrindo aos poucos o que esse framework permitia ser feito, de forma simples ele atribuiu N funcionalidades para o uso dos embeddings, tanto da criação dos vetores até a manipulação, como busca de vetor com SQL, análise de grafo e também pipelines com LLM's prontas.

Também dentro do framework é possível entender como que as LLM's "pensam" e conseguindo explicar o modelo de uma forma geral, dá para ter uma noção com o txtai da seguinte forma: É feito uma busca semântica e obtido o resultado, a partir disso dá para ter uma base. Com esse resultado é feita a tokenização e comparando toda a sentença com a busca retirando um token por vez e vendo a similaridade, e a cada token retirado é atribuído o score original da sentença inteira - score da sentença sem o token. Assim consegue saber qual token tinha mais valor semântico para a resposta:

```
# Run a search
embeddings.explain("feel good story", limit=1)

[{'id': '4',
  'score': 0.08329004049301147,
  'text': 'Maine man wins $1M from $25 lottery ticket',
  'tokens': [('Maine', 0.003297939896583557),
             ('man', -0.03039500117301941),
             ('wins', 0.03406312316656113),
             ('$1M', -0.03121592104434967),
             ('from', -0.02270638197660446),
             ('$25', 0.012891143560409546),
             ('lottery', -0.015372440218925476),
             ('ticket', 0.007445111870765686)]}]
```

Aqui podemos ver que as palavras ticket e wins tiveram o maior score, isso faz sentido, já que o modelo associou "feel good story" com ganhar algo. Já os menores scores foram \$1M, e man, já que não atribuem tanto valor como as outras.

Outra forma apresentada é utilizando a biblioteca SHAP que dentro do exemplo dado faz uma análise de sentimentos para 2 sentenças, dizendo se a sentença é negativa ou positiva.

Conclusões

Minha conclusão com o final desse card é que é da mesma importância saber como criar e entender o processo da LLM mas também entender o porquê de tal pergunta obter tal resposta ou do porque tal palavra recebe o mesmo resultado que aquela. Essa parte de aplicabilidade retira um pouco a IA dessa "caixa preta" e conseguimos obter melhores respostas e melhores resultados conseguindo entender por trás de tudo.

Referências

[txtai](#) - Documentação do framework