

Relatório 5 - Estado da Arte em visão Computacional

Lucas Scheffer Hundsdorfer

Descrição da atividade

Primeiro artigo do estado da arte eu para a classificação foi o:

ConvNeXt V2: Co-designing and Scaling ConvNets with Masked Autoencoders

No resumo do artigo é explicado que o que foi feito é a descoberta de uma combinação de 2 abordagens para uma melhora na performance, juntando um aprendizado supervisionado e uma aprendizagem auto supervisionada. Propondo um framework autoencoder mascarado totalmente convolucional junto de uma nova Global Response Normalization adicionado à arquitetura já existente do ConvNeXt. Na introdução é explicado o que foi pensado para chegar nessa nova arquitetura misturando as abordagens e também explica o porquê dessa adição, ao treinar o ConvNeXt diretamente a entrada da máscara poderia ocorrer um colapso de características, fazendo assim necessário utilizar dessa normalização. É dito também que essa arquitetura teve melhoras de performance em várias tarefas, como classificação, detecção e também segmentação. O capítulo 3 propõe o framework Fully Convolutional masked autoencoder, que adapta o pré-treinamento de máscaras para redes convolucionais ao tratar imagens como dados esparsos, impedindo o vazamento de informações. A arquitetura utiliza um encoder convolucional esparsos e um decoder leve, alcançando maior eficiência e precisão ao reconstruir pixels ocultos. No capítulo 4 fala um pouco mais sobre a GRN a forma de normalização dos dados para evitar um possível colapso dos dados, mostrando os cálculos de como é feita essa normalização, o pseudo-código em PyTorch, onde é aplicado na arquitetura e também os ganhos com tal método. O quinto capítulo serve de comparação com outros modelos dentro de datasets famosos para cada task dentro da visão computacional:

Type	Backbone	size	#param	FLOPS	Val acc.
Conv	Efficient V2-XL	480 ²	208M	94.0G	87.3
	ConvNeXt V1-XL	384 ²	350M	179.0G	87.8
Hybrid	CoAtNet-4	512 ²	275M	360.9G	88.1
	MaxViT-XL	384 ²	475M	293.7G	88.5
	MaxViT-XL	512 ²	475M	535.2G	88.7
Trans	MViTV2-H	384 ²	667M	388.5G	88.6
	MViTV2-H	512 ²	667M	763.5G	88.8
Conv	ConvNeXt V2-H	384 ²	659M	337.9G	88.7
	ConvNeXt V2-H	512 ²	659M	600.7G	88.9

Aplicado no ImageNet.

Backbone	Method	FLOPS	AP ^{box}	AP ^{box} ₅₀	AP ^{box} ₇₅	AP ^{mask}	AP ^{mask} ₅₀	AP ^{mask} ₇₅
ConvNeXt V1-B	Supervised	486G	50.3	71.6	56.1	44.9	68.5	48.8
ConvNeXt V2-B	Supervised	486G	51.0	72.4	56.6	45.6	69.5	49.7
Swin-B	SimMIM	497G	52.3	—	—	—	—	—
ConvNeXt V2-B	FCMAE	486G	52.9	72.6	58.9	46.6	70.0	51.1
ConvNeXt V1-L	Supervised	875G	50.6	71.5	56.3	45.1	68.7	49.2
ConvNeXt V2-L	Supervised	875G	51.5	72.5	57.3	45.8	69.4	49.9
Swin-L	SimMIM	904G	53.8	—	—	—	—	—
ConvNeXt V2-L	FCMAE	875G	54.4	73.9	60.4	47.7	71.4	52.3
Swin V2-H	SimMIM	—	54.4	—	—	—	—	—
ConvNeXt V2-H	FCMAE	2525G	55.7	75.2	61.8	48.9	72.8	53.6

Aplicado ao COCO.

Backbone	Method	input	mIoU	#param	FLOPS
ConvNeXt V1-B	Supervised	512 ²	49.9	122M	1170G
ConvNeXt V2-B	Supervised	512 ²	50.5	122M	1170G
Swin-B	SimMIM	512 ²	52.8	121M	1181G
ConvNeXt V2-B	FCMAE	512 ²	52.1	122M	1170G
ConvNeXt V1-L	Supervised	512 ²	50.5	235M	1573G
ConvNeXt V2-L	Supervised	512 ²	51.6	235M	1573G
Swin-L	SimMIM	512 ²	53.5	234M	1601G
ConvNeXt V2-L	FCMAE	512 ²	53.7	235M	1573G
Swin V2-H	SimMIM	512 ²	54.2	—	—
ConvNeXt V2-H	FCMAE	512 ²	55.0	707M	3272G
ConvNeXt V2-H	FCMAE, 22K ft	640 ²	57.0	707M	5113G

Aplicado ao ADE20K. E para finalizar a conclusão traz alguns aspectos mais técnicos, como as configurações de pré treinamento, como foi feito o pré treinamento com imagens mascaradas utilizando convoluções esparsas, as comparações de cada tamanho de modelo no dataset do ImageNet e também os resultados e performance mostrando uma melhoria significativa comparado a versão anterior da arquitetura.

O segundo artigo escolhido para a task de classificação foi:

DaViT: Dual Attention Vision Transformers

Dentro do resumo do artigo é explicado uma nova abordagem que consegue uma nova arquitetura de visão transformer que consegue capturar contexto global de forma eficiente. Utilizando dois mecanismo de “self-attention” que se complementam, o “channel” e “spatial” tokens, cada um com sua função. O “spatial” foca em saber onde estão as coisas basicamente e o “channel” busca dizer o que é. Durante a introdução é dito que o contexto global da imagem é essencial para a visão computacional, porém era complicado porque manter esse contexto global com os mecanismos conhecidos mantinha também o custo computacional alto usando os tokens explicados acima. O artigo se propõe em vez de variar onde a atenção é feita espacialmente, propõe um mecanismo de atenção em nível de imagem inteira usando os channel tokens que é global por construção. No capítulo 3 onde é explicado toda a metodologia do artigo e como a arquitetura é proposta. Organizado em 4 estágios de onde a cada estágio a resolução espacial é reduzida, enquanto o número de canais dobra e dentro de cada estágio esses blocos se alternam: Atenção espacial por janela que divide a imagem em janelas não sobrepostas de P_w patches cada e realiza self-attention dentro de cada janela com múltiplas cabeças. Atenção de canal por grupos que em vez de operar sobre patches, opera na transposta da matriz de tokens. Cada token de canal resume a imagem inteira em P dimensões. Os canais são divididos em N_g grupos de C_g canais, e a atenção é feita dentro de cada grupo. Como cada token é global, a atenção entre eles naturalmente captura interações de longo alcance. Assim fazendo com que esses blocos se complementem. No 4 capítulo é feito a análise da arquitetura comparada a outras arquiteturas diferentes, o Swin que utiliza apenas de atenção local e o DeiT que só usa atenção global. Após a comparação é demonstrado que o Swin não consegue focar no objeto principal até os estágios finais e o DeiT só foca no objeto final e acaba perdendo os outros detalhes, eles usaram essa comparação para demonstrar como a arquitetura apresentada é a melhor dos dois mundos. Dentro do quinto capítulo é demonstrado os experimentos feitos em cada uma das áreas da visão computacional e comprovando ainda mais como essa arquitetura demonstra o estado da arte. Foram conduzidos experimentos em 3 benchmarks, primeiramente no dataset ImageNet-1K de classificação:

Model	#Params (M)	FLOPs (G)	Top-1 (%)	Model	#Params (M)	FLOPs (G)	Top-1 (%)
ResNet-50 [24]	25.0	4.1	76.2	ResNet-152 [24]	60.0	11.0	78.3
DeiT-Small/16 [55]	22.1	4.5	79.8	PVT-Large [63]	61.4	9.8	81.7
PVT-Small [63]	24.5	3.8	79.8	DeiT-Base/16 [55]	86.7	17.4	81.8
ConvMixer-768/32 [57]	21.1	—	80.2	CrossViT-Base [5]	104.7	21.2	82.2
CrossViT-Small [5]	26.7	5.6	81.0	T2T-ViT-24 [75]	64.1	14.1	82.3
Swin-Tiny [40]	28.3	4.5	81.2	CPVT-Base [11]	88.0	17.6	82.3
CvT-13 [65]	20.0	4.5	81.6	TNT-Base [22]	65.6	14.1	82.8
CoAtNet-0 [13]	25.0	4.2	81.6	ViL-Base [82]	55.7	13.4	83.2
CaiT-XS-24 [56]	26.6	5.4	81.8	UFO-ViT-B [50]	64.0	11.9	83.3
ViL-Small [82]	24.6	5.1	82.0	Swin-Base [40]	87.8	15.4	83.4
PVTv2-B2 [62]	25.4	4.0	82.0	CaiT-M24 [56]	185.9	36.0	83.4
UFO-ViT-S [50]	21.0	3.7	82.0	NFNet-F0 [4]	71.5	12.4	83.6
Focal-Tiny [72]	29.1	4.9	82.2	PVTv2-B5 [62]	82.0	11.8	83.8
DaViT-Tiny (Ours)	28.3	4.5	82.8	Focal-Base [72]	89.8	16.0	83.8
ResNet-101 [24]	45.0	7.9	77.4	CoAtNet-2 [13]	75.0	15.7	84.1
PVT-Medium [63]	44.2	6.7	81.2	CSwin-B [17]	78.0	15.0	84.2
CvT-21 [65]	32.0	7.1	82.5	DaViT-Base (Ours)	87.9	15.5	84.6
UFO-ViT-M [50]	37.0	7.0	82.8	Pre-trained on ImageNet-22k			
Swin-Small [40]	49.6	8.7	83.1	Swin-Large [40] †	197.0	103.9	86.4
ViL-Medium [82]	39.7	9.1	83.3	CSWin-B [17] †	78.0	47.0	87.0
CaiT-S36 [56]	68.0	13.9	83.3	CSWin-L [17] †	173.0	96.8	87.5
CoAtNet-1 [13]	42.0	8.4	83.3	CoAtNet-3 [13] †	168.0	107.4	87.6
Focal-Small [72]	51.1	9.1	83.5	DaViT-Base (Ours) †	87.9	46.4	86.9
CSwin-S [17]	35.0	6.9	83.6	DaViT-Large (Ours) †	196.8	103.0	87.5
VAN-Large [21]	44.8	9.0	83.9	Pre-trained on 1.5B image and text pairs			
UniFormer-B [32]	50.0	8.3	83.9	DaViT-Huge (Ours) ‡	362	334	90.2
DaViT-Small (Ours)	49.7	8.8	84.2	DaViT-Giant (Ours) ‡	1437	1038	90.4

Com pré treinamento no ImageNet-22k o DaViT-Large chegou a 87,5% e o DaViT-Giant chega aos 90,4%.

Na parte de detecção usando os frameworks RetinaNet e Mask R-CNN dentro do dataset do COCO:

Backbone	#Params (M)	FLOPs (G)	RetinaNet 3x						Mask R-CNN 3x					
			AP ^b	AP ^b ₅₀	AP ^b ₇₅	AP ^s	AP ^s ₅₀	AP ^s ₇₅	AP ^b	AP ^b ₅₀	AP ^b ₇₅	AP ^m	AP ^m ₅₀	AP ^m ₇₅
ResNet50 [24]	37.7/44.2	239/260	39.0	58.4	41.8	22.4	42.8	51.6	41.0	61.7	44.9	37.1	58.4	40.1
PVT-Small[63]	34.2/44.1	226/245	42.2	62.7	45.0	26.2	45.2	57.2	43.0	65.3	46.9	39.9	62.5	42.8
ViL-Small [82]	35.7/45.0	252/174	42.9	63.8	45.6	27.8	46.4	56.3	43.4	64.9	47.0	39.6	62.1	42.4
Swin-Tiny [40]	38.5/47.8	245/264	45.0	65.9	48.4	29.7	48.9	58.1	46.0	68.1	50.3	41.6	65.1	44.9
Focal-Tiny [72]	39.4/48.8	265/291	45.5	66.3	48.8	31.2	49.2	58.7	47.2	69.4	51.9	42.7	66.5	45.9
DaViT-Tiny (Ours)	38.5/47.8	244/263	46.5	68.1	49.6	32.3	50.6	59.9	47.4	69.5	52.0	42.9	66.8	46.4
ResNeXt101-32x4d [69]	56.4/62.8	319/340	41.4	61.0	44.3	23.9	45.5	53.7	44.0	64.4	48.0	39.2	61.4	41.9
PVT-Medium [63]	53.9/63.9	283/302	43.2	63.8	46.1	27.3	46.3	58.9	44.2	66.0	48.2	40.5	63.1	43.5
ViL-Medium [82]	50.8/60.1	339/261	43.7	64.6	46.4	27.9	47.1	56.9	44.6	66.3	48.5	40.7	63.8	43.7
Swin-Small [40]	59.8/69.1	335/354	46.4	67.0	50.1	31.0	50.1	60.3	48.5	70.2	53.5	43.3	67.3	46.6
Focal-Small [72]	61.7/71.2	367/401	47.3	67.8	51.0	31.6	50.9	61.1	48.8	70.5	53.6	43.8	67.7	47.2
DaViT-Small (Ours)	59.9/69.2	332/351	48.2	69.7	51.7	32.7	52.2	62.9	49.5	71.4	54.7	44.3	68.4	47.6
ResNeXt101-64x4d [69]	95.5/102	473/493	41.8	61.5	44.4	25.2	45.4	54.6	44.4	64.9	48.8	39.7	61.9	42.6
PVT-Large[63]	71.1/81.0	345/364	43.4	63.6	46.1	26.1	46.0	59.5	44.5	66.0	48.3	40.7	63.4	43.7
ViL-Base [82]	66.7/76.1	443/365	44.7	65.5	47.6	29.9	48.0	58.1	45.7	67.2	49.9	41.3	64.4	44.5
Swin-Base [40]	98.4/107.0	477/496	45.8	66.4	49.1	29.9	49.4	60.3	48.5	69.8	53.2	43.4	66.8	46.9
Focal-Base [72]	100.8/110.0	514/533	46.9	67.8	50.3	31.9	50.3	61.5	49.0	70.1	53.6	43.7	67.6	47.0
DaViT-Base (Ours)	98.5/107.3	471/491	48.7	70.0	52.3	33.7	52.8	62.9	49.9	71.5	54.6	44.6	68.8	47.8

o DaViT-Tiny supera o Focal-Tiny em APb tanto no schedule 1× quanto 3×. O DaViT-Base atinge 48,7 APb no RetinaNet 3×, superando todos os modelos comparados na mesma faixa.

Já para a área de segmentação semântica foi utilizado o dataset ADE20k com o framework UperNet:

Backbone	Method	#Params (M)	FLOPs (G)	mIoU (%)
Swin-Tiny [40]	UperNet [67]	60	945	44.5
PVT-Large [63]	SemanticFPN [36]	65	318	44.8
HRNet-w48 [60]	OCRNet [78]	71	664	45.7
Focal-Tiny [72]	UperNet [67]	62	998	45.8
XCiT-S12/16 [1]	UperNet [67]	52	—	45.9
Twins-SVT-Small [10]	UperNet [67]	54	912	46.2
DaViT-Tiny (Ours)	UperNet [67]	60	940	46.3
ResNet-101 [24]	UperNet [67]	86	1029	44.9
XCiT-S24/16 [1]	UperNet [67]	73	—	46.9
Swin-Small [40]	UperNet [67]	81	1038	47.6
Twins-SVT-Base [10]	UperNet [67]	88	1044	47.7
Focal-Small [72]	UperNet [67]	85	1130	48.0
ResNeSt-200 [81]	DLab.v3+ [6]	88	1381	48.4
DaViT-Small (Ours)	UperNet [67]	81	1030	48.8
Swin-Base [40]	UperNet [67]	121	1188	48.1
XCiT-M24/8 [1]	UperNet [67]	109	—	48.4
Twins-SVT-Large [10]	UperNet [67]	133	1188	48.8
ViT-Hybrid [45]	DPT [45]	124	1231	49.0
Focal-Base [72]	UperNet [67]	126	1354	49.0
DaViT-Base (Ours)	UperNet [67]	121	1175	49.4

DaViT também alcança mIoU superior aos concorrentes nas três versões de tamanho.

Já a conclusão do DaViT demonstra que é possível capturar contexto global de forma eficiente sem recorrer a operadores especiais como janelas deslocadas ou downsampling. A combinação dos dois tipos de atenção é simples de implementar, mantém complexidade linear, e generaliza bem para classificação, detecção e segmentação. Os autores apontam que a arquitetura escala bem com mais dados e parâmetros, o que abre caminho para modelos ainda maiores.

Para o terceiro artigo que se encaixa no estado da arte na task de classificação:

CoCa: Contrastive Captioners are Image-Text Foundation Models:

Dentro do resumo é explicado que CoCa vem de Contrastive Captioner, um modelo que unifica duas abordagens de pré-treinamento, o aprendizado contrastivo e o aprendizado generativo. Aplicado com duas funções de loss, um contrastivo e o outro “captioning loss” e como ambos objetivos dividem o mesmo grafo computacional ambos são computados de forma eficiente com sobrecarga mínima. Durante a introdução é explicado e contextualizado o cenário da visão computacional, explicando que existem 3 tipos de modelos, modelos e classificação com encoder único, modelos contrastivos com encoder duplo e por fim os modelos generativos encoder-decoder, citando os pontos fortes e fracos de cada um. Propondo a arquitetura CoCa como o melhor de todos os casos, conseguindo absorver os pontos fortes de ambos. O capítulo 3 traz a abordagem, e dá uma detalhada melhor em como a arquitetura funciona de fato, dividida em 3 componentes principais, encoder de imagem, decoder de texto unimodal e um decoder de texto multimodal. O ponto diferencial foi nos decoders onde a primeira metade atua sem cross-attention gerando representações textuais e a segunda metade atua aciona o cross-attention gerando representações imagens-texto permitindo extrair simultaneamente embeddings multimodais. O modelo é pré-treinado do zero em dados de alt-text da web em escala e em dados anotados, tratando todos os rótulos simplesmente como texto. No 4 capítulo vai ser passado sobre o ambiente experimental dos treinamentos e os principais resultados, junto também da investigação da proporção ideal entre as camadas unimodais e multimodais no decoder, concluindo que dividir as camadas ao meio mantém o melhor equilíbrio entre as duas capacidades: poucas camadas unimodais prejudicam a classificação zero-shot por falta de capacidade para representações textuais puras, enquanto poucas camadas multimodais reduzem o desempenho em tarefas de compreensão como VQA. A conclusão demonstra que é possível unificar aprendizado contrastivo e generativo em uma única arquitetura simples e

eficiente, pré-treinada do zero sem depender de modelos previamente treinados. O CoCa elimina a necessidade de pipelines separados para diferentes tarefas, oferecendo um único checkpoint que se adapta a reconhecimento, recuperação, compreensão e geração com ajuste mínimo.

Para o 4 artigo e o primeiro da task de detecção de objetos:

YOLOv7: Trainable bag-of-freebies sets new state-of-the-art for real-time object detectors

No resumo do artigo é explicado como foram feitas as novas abordagens para que conseguisse um estado da arte. A proposta central é um conjunto de métodos chamados trainable bag-of-freebies. Essa arquitetura alcançou todos os detectores da época num range de 5 a 120 fps atingindo o ápice de 56,8% AP. Na introdução é explicado como os detectores em tempo real funcionavam, e mostra também que ao resolver alguns erros eles encontraram mais erros com essa abordagem. Também fala das contribuições do artigo, primeiro o desenvolvimento desse novo método (bag-of-freebies) que aumenta a performance do modelo sem aumentar a inferência, a segunda contribuição é os problemas que vem com o método, são dois: como o módulo de re-parametrização deve substituir módulos originais em diferentes arquiteturas, e como a estratégia de atribuição dinâmica de rótulos deve funcionar em modelos com múltiplas camadas de saída. No capítulo 2.1 é explicado que com esse método não era buscado desenvolver uma rede mais forte, mais eficiente ou com mais acurácia, e sim buscar uma função de loss mais robusta, uma atribuição de rótulos mais eficiente e também um método de treinamento mais eficaz. No capítulo 3 é explicado e detalhado toda a arquitetura. O bloco central é o E-ELAN Extended Efficient Layer Aggregation Network, que a função é expandir a cardinalidade dos blocos computacionais, permitindo que diferentes grupos aprendam features mais diversas. Além disso, é proposto um método de escalonamento composto específico para modelos baseados em concatenação. No capítulo 4 é falado sobre os métodos que compõem o trainable bag-of-freebies, um é o modelo de re-parametrização planejada, ao invés de aplicar RepConv, os autores analisam os caminhos de propagação do gradiente para determinar onde a conexão do RepConv deve ser ou não aplicada. No 5 capítulo é falado sobre os experimentos conduzidos em cima do dataset MS COCO, o YOLOv7 com 36,9M de parâmetros alcançou 51,2% AP. Reduzindo em 43% os parâmetros e 15% os FLOPs em relação ao YOLOR-CSP. Estudos de ablação que validam individualmente o método de escalonamento composto, o modelo de re-parametrização planejada e o método de atribuição de rótulos com cabeça auxiliar, confirmando a contribuição positiva de cada componente. A conclusão demonstra que focar na otimização do treinamento, e não apenas da arquitetura, é uma direção válida e eficaz para avançar o estado da arte em detecção de objetos em tempo real.

O segundo artigo para a task de detecção:

EfficientDet: Scalable and Efficient Object Detection.

Dentro do resumo é explicado que baseado nas otimizações da camada de backbone do EfficientNet, foi desenvolvida uma nova família de detecção de objetos que alcança resultados bem mais consistentes que no que foi baseado, chegando a 52.2 AP no COCO com 52M de parâmetros. Dentro da introdução é falado que de acordo com a evolução da detecção para se alcançar o estado da arte foi ficando cada vez mais caro, como exemplo o AmoebaNet que requer 167M de parâmetros inviabilizando para uso em produção. Os principais desafios são, o primeiro é a fusão eficiente de features em múltiplas escalas, onde os métodos anteriores somavam features de diferentes resoluções sem distinguir a importância de cada uma. Já o segundo problema é o escalonamento do modelo, onde os trabalhos anteriores escalavam apenas uma vez por dimensão. O terceiro capítulo já traz uma maneira de tentar tratar com o primeiro problema citado, o BiFPN. O FPN convencional possui fluxo de informação apenas top-down, e o PANet adiciona um caminho bottom-up, mas com custo maior. O BiFPN parte

dessas ideias e aplica três otimizações: remove nós com apenas uma aresta de entrada por contribuírem pouco para a fusão, adiciona conexões diretas entre nós de mesmo nível para enriquecer a fusão sem custo relevante, e repete o bloco bidirecional múltiplas vezes para aumentar a fusão de alto nível. No capítulo 4 é descrita a arquitetura completa do EfficientDet, que surgiu a partir das otimizações propostas no capítulo anterior. A arquitetura mantém o backbone EfficientNet pré-treinado no ImageNet. BiFPN atua como rede de features, recebendo as features dos níveis 3 a 7 do backbone e aplicando repetidamente a fusão bidirecional. Cabeças compartilhadas de predição de classe e bounding box são utilizadas em todos os níveis de features. No quinto capítulo onde se passa os experimentos dentro do dataset COCO dentro da família do EfficientDet com os modelos com menos parâmetros já é demonstrado que ele tem mais acurácia com menos FLOPs que outros modelos. E o melhor modelo da família atinge 52,2% no conjunto de teste sendo mais rápido do que os detectores anteriores com uma acurácia similar. A conclusão reafirma que estudar sistematicamente as escolhas de arquitetura para detecção eficiente, em vez de apenas aumentar modelos existentes, é uma direção mais promissora. O EfficientDet demonstra que é possível alcançar estado da arte em acurácia com uma fração dos recursos computacionais dos detectores anteriores, sendo válido tanto para detecção quanto para segmentação semântica.

Para o terceiro artigo dentro da área de detecção:

End-to-End Object Detection with Transformers

Dentro do resumo do artigo, é apresentado uma nova forma de detecção de objetos de uma forma que seja dispensado algumas etapas do processo manual, como o non-maximum suppression e geração de âncoras, substituindo o pipeline convencional por uma função de perda baseada em matching bipartido e uma arquitetura transformer. Dentro da introdução é contextualizado o problema, os detectores só detectam de forma indireta, dependendo fortemente de etapas de pós-processamento. O DETR propõe tratar a detecção diretamente como um problema de predição de conjuntos, eliminando essas dependências e possibilitando um treinamento end-to-end. No capítulo 3 é detalhado o modelo, e seus 2 principais ingredientes, a função de perda baseada em Hungarian matching e uma arquitetura que prediz (em um passo) um conjunto de objetos. O backbone CNN extrai features da imagem, que são achatadas e somadas a encodings posicionais fixos antes de entrar no encoder transformer. O encoder aplica self-attention global para raciocinar sobre as relações espaciais entre todos os patches da imagem. O decoder recebe um conjunto fixo de N embeddings aprendíveis chamados object queries e, através de self-attention e cross-attention com a saída do encoder, produz N predições em paralelo. No capítulo 4 são apresentados os experimentos, utilizando o COCO como dataset. No resultado principal o DETR com o ResNet-50 alcança 42 AP no conjunto de validação, comparável ao Faster R-CNN com o mesmo backbone. Os estudos mostraram a importância de cada componente, remover as camadas de encoder causa uma queda de 3,9 AP e a ausência do FFN reduz em 2,3. É demonstrado que o DETR generaliza bem para números de instâncias não vistos durante o treinamento, detectando corretamente até 50 objetos da mesma classe em imagens sintéticas fora da distribuição. A conclusão reafirma que o DETR representa uma mudança de paradigma ao simplificar radicalmente o pipeline de detecção, unificando a predição de coisas e fundo em segmentação panóptica de forma natural. Os autores reconhecem que o modelo ainda apresenta desafios, em particular no desempenho em objetos pequenos e no tempo de treinamento mais longo, e apontam esses pontos como direções para trabalhos futuros.

O primeiro artigo de segmentação escolhido foi o:

Dentro do resumo é explicado que Segment Anything é um novo modelo, e um novo dataset para segmentação de imagens, foi construído o maior dataset de segmentação com 1 bilhão de máscaras com 11 milhões de imagens licenciadas e com proteção de privacidade. O modelo é projetado para possibilitar transferência zero-shot. Na introdução é contextualizado o cenário

dos modelos fundacionais, inspirados pelo sucesso de LLM 's como o GPT que generalizam tarefas via prompt engineering. O objetivo é criar um equivalente para segmentação de imagens, um modelo treinando em larga escala capaz de se adaptar a qualquer tarefa de segmentação sem retreinamento. No segundo capítulo é definida a tarefa de segmentação por prompts, o SAM aceita qualquer tipo de prompt, pontos, caixas, máscaras e até texto. Retornando uma máscara de segmentação válida. Até mesmo prompts ambíguos produzem uma máscara razoável, exigindo que o modelo seja conscientemente ambíguo. Essa tarefa serve tanto como objetivo de pré-treinamento quanto como mecanismo de transferência zero-shot para tarefas downstream via engenharia de prompts. No terceiro capítulo é onde é mostrado de forma mais detalhada toda a arquitetura, composta por três componentes: encoder de imagem, prompt encoder e o decoder de máscara. O encoder de imagens usa um ViT pré treinado com MAE e toda uma vez por imagem. O encoder de prompts trata prompts esparsos como pontos e caixas via encoding posicionais, e prompts densos como máscaras via convolução. E o decoder de máscaras usa atenção cruzada bidirecional entre embedding de imagem e prompt para produzir até 3 máscaras simultaneamente. No 4 capítulo é descrito o motor de dados que viabilizou a construção do dataset de 1 bilhão de máscaras. No estágio assistido-manual, os anotadores usavam o SAM para rotular máscaras. No estágio semi-automático, o SAM gerava máscaras para os maiores objetos e os anotadores focavam no restante. E no estágio automático o modelo era promovido com uma grade de 32x32 e gerava automaticamente todas as máscaras, produzindo cerca de 100 imagens por imagem em todo o dataset. O quinto capítulo é apresentado o dataset que tem 400x mais máscaras do que o segundo maior dataset de segmentação existente. Uma verificação confirmou que 94% das máscaras automáticas têm IoU acima de 90% em relação às correções manuais. No capítulo 6 são apresentados os experimentos de transferência zero-shot em 23 datasets com distribuições diversas. Na avaliação com um único ponto de foreground, o SAM supera o baseline RITM em 16 dos 23 datasets, e nas avaliações humanas recebe notas médias entre 7 e 9 de 10, consistentemente superiores ao baseline. A conclusão reconhece que o SAM representa uma tentativa de elevar a segmentação de imagens à era dos modelos fundacionais. Os autores apontam limitações como dificuldades com estruturas finas, objetos pequenos e segmentação semântica via prompts simples, e afirmam que o impacto real do trabalho dependerá de como a comunidade utilizará o modelo e o dataset liberados.

O segundo artigo é para a área de segmentação:

Mask2Former: Masked-attention Mask Transformer for Universal Image Segmentation

Dentro do resumo do artigo é falado o Mask2Former que é capaz de atuar em qualquer tarefa de segmentação com a mesma arquitetura. O componente central é a atenção mascarada, que extrai features localizadas restringindo o cross-attention nas regiões das máscaras previstas. Resultando em 57.8 PQ no COCO na tarefa de segmentação panóptica, 50.1 AP no COCO na tarefa de segmentação de instâncias e 57.7 mIoU no ADE20K na segmentação semântica. Na introdução é explicado o porquê do desenvolvimento dessa arquitetura única para as três tarefas dentro da segmentação. A área vinha desenvolvendo arquiteturas especializadas para cada uma, gerando esforço na hotra da pesquisa e otimização. Uma arquitetura universal para segmentação anteriores tentaram resolver isso só que não traziam a eficiência que as arquiteturas especializadas conseguiam e sendo também mais difíceis de treinar. O Mask2Former é proposto como o primeiro a resolver esses gargalos. No capítulo 3 é detalhada a arquitetura, foi herdado uma parte do MaskFormer como o backbone, pixel decoder e transformer decoder. E como proposta o Mask2Former trouxe 4 novidades, primeiro a atenção mascarada substituindo o cross-attention padrão, acelerando as convergências e melhorando o desempenho, a segunda novidade são as features multi-escala de alta resolução, que são introduzidas de forma eficiente, sem custo computacional excessivo. A terceira novidade são as melhorias de otimização que inclui a inversão da ordem de self e cross-attention que ganha desempenho sem custo adicional. E por fim o cálculo da loss de máscaras sobre pontos

amostrados aleatoriamente em vez de máscaras completas reduzindo o consumo em 3 vezes. No quarto capítulo são apresentados os experimentos nos quatro datasets (COCO, ADE20K, Cityscapes, Mapillary Vistas). Na segmentação panóptica o Mask2Former com backbone Swin-L atinge 57,8 PQ no COCO. Na segmentação de instâncias atinge 50,1 AP no COCO. Na segmentação semântica atinge 57,7 mIoU no ADE20K. Os estudos confirmam que a atenção mascarada é o componente com maior impacto, causando queda de 5,9 AP e 4,8 PQ quando removida. Os autores também identificam como limitação que o modelo ainda precisa ser treinado separadamente para cada tarefa e apresenta dificuldades com objetos pequenos. A conclusão reafirma que o Mask2Former demonstra que arquiteturas universais podem substituir as especializadas sem sacrifício de desempenho, reduzindo em 3x o esforço de pesquisa. Os autores apontam como direção futura o desenvolvimento de um modelo treinado uma única vez para todas as tarefas e datasets simultaneamente.

O último artigo da área de segmentação:

SegFormer: Simple and Efficient Design for Semantic Segmentation with Transformers:

Dentro do resumo é dito que o SegFormer é um framework de segmentação semântica que unifica transformers com decoders leves baseados em MLP. Suas duas contribuições centrais são um encoder transformer hierárquico que gera features multi-escala sem necessidade de positional encoding, e um decoder All-MLP leve que combina atenção local e global para produzir representações poderosas. Indo de SegFormer-B0 até SegFormer-B5 com o maior modelo atingindo 51,8% mIoU no ADE20K e 84% mIoU no Cityscapes. Na introdução é contextualizado o problema: os modelos anteriores baseados em transformer para segmentação semântica, como o SETR, focavam principalmente no design do encoder e negligenciavam a contribuição do decoder, além de serem computacionalmente pesados e de difícil implantação em tempo real. O SegFormer se propõe a redesenhar tanto o encoder quanto o decoder de forma conjunta, buscando eficiência, acurácia e robustez ao mesmo tempo. No capítulo 3 é detalhada a arquitetura, o encoder MiT utiliza patches sobrepostos de tamanho 4x4 favorecendo a predição densa. Para reduzir o custo do self-attention, é aplicada uma redução de sequência de K e V antes do cálculo da atenção. O decoder All-MLP opera em quatro passos: unifica as dimensões dos canais de cada nível via MLP, faz upsampling de todas as features para 1/4 da resolução original, concatena e funde com outro MLP, e por fim prediz a máscara de segmentação. Dentro do quarto capítulo é apresentado os experimentos, os estudos confirmam que o Mix-FFN supera o positional encoding tradicional em diferentes resoluções de teste, com queda apenas de 0,7% de mIoU ao mudar a resolução contra 3,3% com positional encoding. Nas comparações com o estado da arte, o SegFormer-B0 com apenas 3,8M de parâmetros supera o DeepLabV3+ em velocidade e acurácia no Cityscapes em tempo real. O SegFormer-B5 atinge 51,8% mIoU no ADE20K sendo 4x menor e mais eficiente que o SETR, e 84,0% mIoU no Cityscapes, superando todos os métodos anteriores. A conclusão reafirma que o design simples e limpo do SegFormer sem positional encoding e com um decoder leve é a chave para eficiência e robustez em segmentação semântica com transformers. Os autores identificam como limitação a incerteza sobre o funcionamento do modelo menor em dispositivos de borda com memória muito restrita, deixando essa investigação para trabalhos futuros.

Dificuldades

A primeira dificuldade foi achar os artigos para ler, precisa de uma boa pesquisa para encontrar o que seria o estado atual da arte para estes 3 campos.

Dificuldade dada ao fato de eu não ser fluente em inglês e todos os artigos serem em inglês.

Conclusões

A pesquisa realizada neste relatório permitiu um entendimento do estado da arte em três das principais tarefas da visão computacional, classificação de imagens, detecção de objetos e segmentação. Ficou evidente que a área vive um momento de transformação acelerada, onde arquiteturas baseadas em transformers passaram a dominar tarefas que por anos foram dominadas por redes convolucionais. Além dos avanços técnicos, o estudo desses artigos trouxe uma compreensão mais clara de como a pesquisa funciona na prática, como os autores identificam limitações dos trabalhos anteriores, propõem soluções, validam com experimentos e reconhecem as próprias limitações. Esse processo, repetido em cada um dos artigos, mostrou que o avanço científico é incremental e construído sobre o trabalho de outros.

Referências

ConvNeXt V2: Co-designing and Scaling ConvNets with Masked Autoencoders:

<https://arxiv.org/pdf/2301.00808>

DaViT: Dual Attention Vision Transformers:

<https://arxiv.org/pdf/2204.03645>

<https://github.com/dingmyu/davit>

CoCa: Contrastive Captioners are Image-Text Foundation Models

<https://arxiv.org/pdf/2205.01917>

CoCa: Contrastive Captioners are Image-Text Foundation Models

https://openaccess.thecvf.com/content/CVPR2023/papers/Wang_YOLOv7_Trainable_Bag-of-Freebies_Sets_New_State-of-the-Art_for_Real-Time_Object_Detectors_CVPR_2023_paper.pdf

<https://github.com/WongKinYiu/yolov7>

EfficientDet: Scalable and Efficient Object Detection

https://openaccess.thecvf.com/content_CVPR_2020/papers/Tan_EfficientDet_Scalable_and_Efficient_Object_Detection_CVPR_2020_paper.pdf

<https://github.com/google/automl/tree/master/efficientdet>

End-to-End Object Detection with Transformers

<https://arxiv.org/pdf/2005.12872>

<https://github.com/facebookresearch/detr.t>

Segment Anything

https://openaccess.thecvf.com/content/ICCV2023/papers/Kirillov_Segment_Anything_ICCV_2023_paper.pdf

<https://github.com/facebookresearch/segment-anything>

Masked-attention Mask Transformer for Universal Image Segmentation

https://openaccess.thecvf.com/content/CVPR2022/papers/Cheng_Masked-Attention_Mask_Transformer_for_Universal_Image_Segmentation_CVPR_2022_paper.pdf

<https://github.com/facebookresearch/Mask2Former>

SegFormer: Simple and Efficient Design for Semantic Segmentation with Transformers

<https://arxiv.org/pdf/2105.15203>

<https://github.com/NVlabs/SegFormer>